

Metody Statystyczne  
wykład 3

5 XII 2020

kacper.topolnicki@~~uj~~uj.edu.pl


Plan:

- rozkład normalny
- estymacji punktowej
- estymacja przedziałowa
- procesy stochastyczne
  - Zmienney Markowa

[możliwość normalny

(X, Y)

założenia:




-  $X, Y$  - niezależne zmienne losowe, bieżący RGP

- FGP dla  $X, Y$  jest ciągła i symetryczna względem 0

- FGP dla  $X, Y \rightarrow 0$  „daleko” od  $X=0, Y=0$

$$f_{X,Y}(-x) = f_{X,Y}(x) \quad , \quad f_{X,Y}(x) \rightarrow 0 \text{ gdy } x \rightarrow \pm \infty$$



$dx, dy \gg \text{molecule}$

$\vec{r}(x, y)$   
RGP alla  $X$  on  $X$

$$\Delta P = \int x(u) du \cdot \int y(v) dv = \int \vec{r}(u, v) du dv$$


$$\int x = \int y = \int \downarrow$$

$$\int(u) \int(v) du dv = \int \vec{r}(u, v) du dv$$

$$f_{\vec{r}}(u, v) = f(u) \cdot f(v)$$

$$f_{\vec{r}}(x, y) = f(x^2 + y^2)$$

$$f_{\vec{r}}(r, \theta)$$



$$\begin{cases} u = r \cos \theta \\ v = r \sin \theta \end{cases}$$

$$\frac{\partial^2 f_{\vec{r}}(r, \theta)}{\partial \theta^2} = f(u) \frac{\partial^2 f(v)}{\partial \theta^2} + \frac{\partial^2 f(u)}{\partial \theta^2} f(v)$$

$$0 = f(u) \cdot \frac{\partial f(u)}{\partial \theta} + \frac{\partial f(u)}{\partial \theta} f(v)$$

$\pi \sin(\theta)$ 
 $\pi \cos(\theta)$

$$0 = f(u) \cdot f'(v) \underbrace{\pi \cos(\theta)}_u + \underbrace{(-\pi \sin \theta)}_v f'(u) f(v)$$

$$v f'(u) f(v) = u f(u) f'(v)$$


$$\frac{f'(u)}{u f(u)} = \frac{f'(v)}{v f(v)} \left. \begin{array}{l} \text{spettimo che} \\ \text{vale per } u, v \end{array} \right\}$$

$$\frac{f'(u)}{u f(u)} = C$$

$$f'(u) = C u \cdot f(u)$$

$$\frac{f'(v)}{v f(v)} = C$$

$$f'(v) = C v f(v)$$



$$e^x = \exp(x)$$

$$\downarrow c < 0 \text{ on } \int_{-\infty}^{\infty} du f(u) = 1$$

$$\left( \begin{array}{l} f(u) \stackrel{\mu=0}{=} \frac{1}{\sigma \sqrt{2\pi}} \exp\left(-\frac{1}{2} \frac{(u-\mu)^2}{\sigma^2}\right) \\ f(u) \stackrel{\mu=0}{=} \frac{1}{\sigma \sqrt{2\pi}} \exp\left(-\frac{1}{2} \frac{(u-\mu)^2}{\sigma^2}\right) \end{array} \right)$$

normalized Normality



$\sigma^2$  — wariancja

$\mu$  — wartość oczekiwana

$$\underbrace{X, X}$$

$$\underbrace{Z = X + X}$$


rozkład normalny

zależy o FGP

↑ zadanie domowe

— w materiałach dodatkowych — centralne  
twierdzenie  
g graniczne


Testy macja punktowa



$$E(x) = \int_{-\infty}^{+\infty} dx f(x) \cdot x \quad \sigma^2 = \int_{-\infty}^{+\infty} dx f(x) (x - E(x))^2$$

$\rho_{x,y}$  - współczynnik korelacji!  
 albo 2 zmienne losowe.

$\mathbb{E}$  w praktyce



czyli po prostu: zamiast PDF

dane:  $\{x_1, x_2, x_3, \dots, x_n\}$

jak oszacować  $E(x)$ ,  $\sigma(x)$ ,  $S(x)$ ?

[[ jakich wartości osiągnęły?

$T_n(a)$  — жана  $a$  — жана  $a$

- estimator use of  $\bar{y}$  (unbiased estimator)

$$E(T_M(\theta)) = \theta_0$$

kažele  $x_i$  jest brova me  $z$   $\rightarrow$  vektor  $\phi$  dle  $\frac{1}{\sqrt{2}}(x)$

smotaj po  $(x_1, x_2, x_3, \dots, x_n)$

- estymator zgodny  
(consistent estimator)

ogólna  
formuła

$$\lim_{N \rightarrow \infty} T_N(\theta) = \theta_0$$

zbieżność losowa pomiarów

$$\text{dla każdego } \epsilon: \lim_{N \rightarrow \infty} P(|T_N(\theta) - \theta_0| > \epsilon) = 0$$

- pught ad



$\{x_1, x_2, x_3, \dots, x_w\}$

$$T_n(\mathbb{E}(X)) = \frac{1}{N-1} \sum_{i=1}^N x_i$$

$$\mathbb{E}(T_n(\mathbb{E}(X))) = \mathbb{E}\left(\frac{1}{N-1} \sum_{i=1}^N x_i\right) =$$

$$= \frac{1}{N-1} \mathbb{E}\left(\sum_{i=1}^N x_i\right) = \frac{1}{N-1} \sum_{i=1}^N \mathbb{E}(x_i) =$$

$$= \frac{1}{N-1} \sum_{i=1}^N \mathbb{E}(X) = \frac{N}{N-1} \mathbb{E}(X)$$

↑ losowo me  
~~z tego samego~~  
 z tego samego PGP

$$\underbrace{E(T_N(R(x))) = \frac{N}{N-1} R(x)}$$

estimator obnoxious.  
(biased estimator)

$$\underbrace{\frac{N}{N-1} R(x) \xrightarrow{n \rightarrow \infty} R(x)}_{\text{estimator good}}$$

- asymptotycznie normalny  

$$FGP\left(\underbrace{T_N(\theta)}\right) \xrightarrow{P \rightarrow \infty} \text{rozkład normalny}$$
  
 zmienna ~~losowa~~ losowa

Testy mające predyktorowa  

$$T_N(\theta)$$
  

$$\downarrow$$

$$\left[ \underbrace{T_N^L(\theta), T_N^R(\theta)} \right]$$
  
 predykt afności



$$P \left( T_N^L(\theta) \leq \theta \leq T_N^R(\theta) \right) =$$

$$= 1 - \underset{\substack{\uparrow \\ \text{nie ulega} \\ \text{pozio} \text{m} \text{ u} \text{f} \text{no} \text{ci} \\ \approx 0.3}}{\alpha} = \underset{\substack{\uparrow}}{\gamma}$$

[[ wartość oczekiwana

[[ założenie:  $\sigma(X)$  znane.

$$Z = \frac{\overline{X} - E(X)}{\sigma(\overline{X})} = \frac{1}{n} \sum_{i=1}^n X_i$$


$$= \frac{(\overline{X} - E(X)) \sqrt{n}}{\sigma(X)}$$

FGP(Z) — rozkład normalny

$$N(0, 1)$$

$$P(z^L \leq z \leq z^R) = \gamma_{z, 0.9}$$

kwantyle rozkładu normalnego  
FGP



$$z^L = z_{\frac{1-\gamma}{2}} = -z_{\frac{\gamma+1}{2}}$$

$$z^R = z_{\frac{\gamma+1}{2}}$$

$$P(z^L \leq z \leq z^R) = \gamma =$$

$$= P\left(z^L \leq \frac{(\bar{x} - E(x)) \sqrt{n}}{\sigma(x)} \leq z^R\right) =$$

$$= P\left(\frac{z^L \sigma(x)}{\sqrt{n}} \leq \bar{x} - E(x) \leq \frac{z^R \sigma(x)}{\sqrt{n}}\right) =$$

$$= P\left(\frac{z^L \sigma(x)}{\sqrt{n}} - \bar{x} \leq -E(x) \leq \frac{z^R \sigma(x)}{\sqrt{n}} - \bar{x}\right) =$$

$$= P\left(\bar{x} - \frac{z^L \sigma(x)}{\sqrt{n}} \geq E(x) \geq \bar{x} - \frac{z^R \sigma(x)}{\sqrt{n}}\right) = \dots$$

$$\dots = P \left( \underbrace{\bar{X} - \frac{z_{1-\alpha/2} \sigma(x)}{\sqrt{N}}}_{T_N^L(\bar{X}(x))} \leq \bar{X}(x) \leq \underbrace{\bar{X} + \frac{z_{1-\alpha/2} \sigma(x)}{\sqrt{N}}}_{T_N^R(\bar{X}(x))} \right)$$

prediction of  $\mu(x)$

III nie znamy  $\sigma(x)$

$N$  - pomiarów

$$t = \frac{(\bar{x} - \mu(x)) \sqrt{N}}{s(x)}$$

$\uparrow$

$$\frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

$\uparrow$


FGP(t)

→ rozkład studenta

o  $N-1$  stopniach  
swobody

$$P\left(\bar{x} - \frac{1}{\sqrt{N}} S \cdot t_{\frac{1+\alpha}{2}} \leq R(x) \leq \bar{x} + \frac{1}{\sqrt{N}} S \cdot t_{\frac{1+\alpha}{2}}\right) = \gamma$$

kwantyl methoden student



$$\left[ \frac{1}{N} \sum_{i=1}^N (R(x_i)) , \frac{1}{N} \sum_{i=1}^N (R(x_i)) \right]$$





[[ nobody & nejdlo wonse esty mto now

— w materioted do do though

[procesy stochastyczne

$X$  - zmienna losowa

$$X: \Omega \rightarrow \mathbb{R}$$

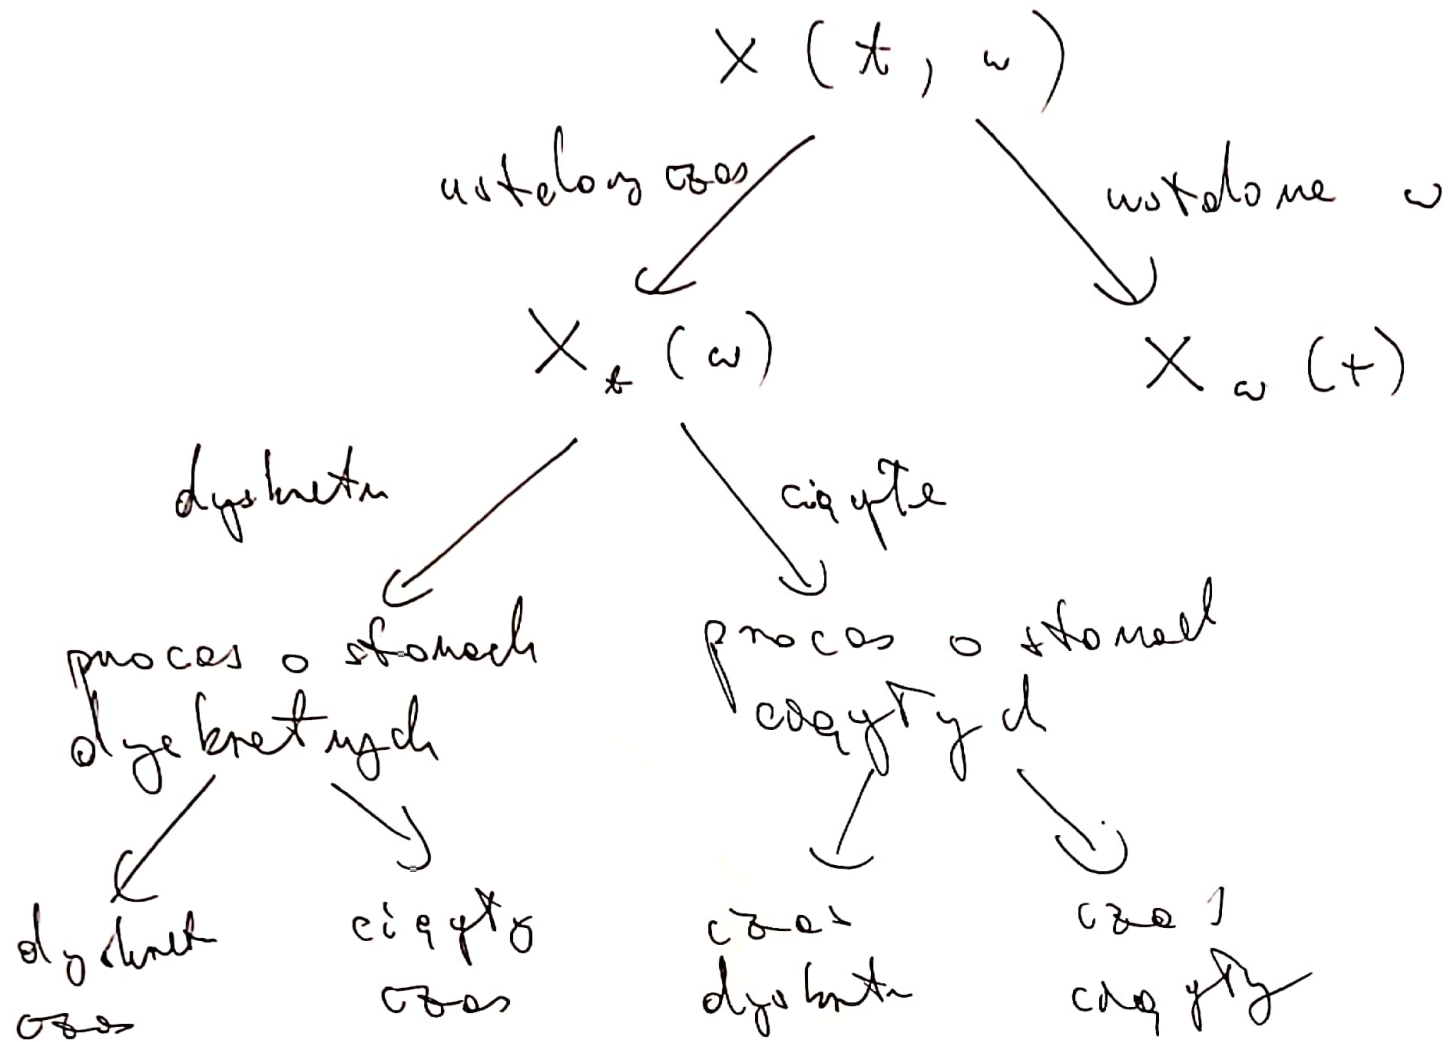
↑  
zbiór zdarzeń  
elementarych

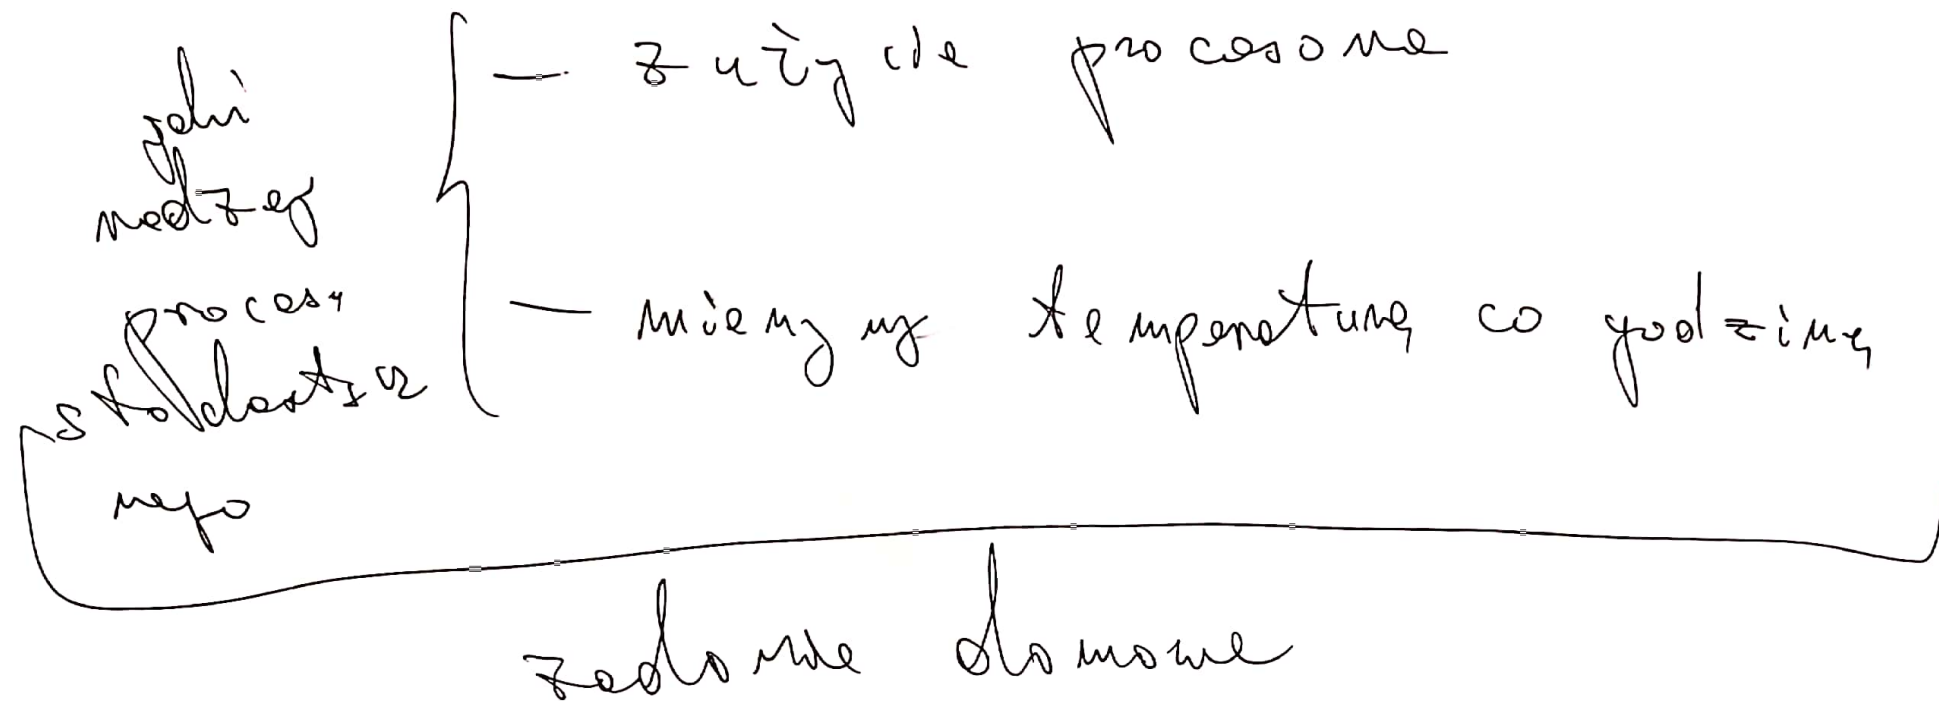
↑  
liczba

$$X(\boxed{\omega}) = 2$$

czas      zmi. losowa

$$\underbrace{X(t, \omega)}_{\text{proces stochastyczny}}$$





[[ processy Markova

$$P(X(t) \in A \mid X(t_1) \in A_1 \wedge X(t_2) \in A_2 \wedge \dots \wedge X(t_n) \in A_n) =$$

$$= P(X(t) \in A \mid X(t_n) \in A_n)$$

$$t_1 < t_2 < \dots < t_n < t$$

$$P(\text{preslovici} \mid \text{kasotmizovici, preslovici}) =$$
$$= P(\text{preslovici} \mid \text{kasotmizovici})$$

- Anageltonis Gelistone podok.

- Anageltonie pdeke z kothy  
pamela

czy to są procesy Markowa?

[[ Rozumuch Markowa

- dyskretny czas  $t = 0, 1, 2, \dots$
- dyskretna przestrzeń  $x = 0, 1, 2, \dots$

$$P(x(t+1)=j \mid x(t)=i) =$$

$$= P(x(t+1)=j \mid x(0)=a \wedge x(1)=b \wedge \dots \wedge x(t)=i)$$

$$P_{ij}(t) \equiv P(x(t+1)=j \mid x(t)=i)$$


$$(p_{ij}(t) = p_{ij})$$

jednostkowy Tworzył Monks

- nie zależy od czasu



III jak określić proces Markowa



- pseudo probabilities  $P_0(x)$
- pseudo probabilities  $P_{ij}$  always  $x$

stan  $\rightarrow (P(1), P(2), \dots)$   
 w danym czasie

$$P_{ij} \rightarrow \begin{pmatrix} P_{11} & P_{12} & \dots \\ P_{21} & P_{22} & \dots \\ \vdots & \vdots & \ddots \end{pmatrix}$$

$$(P_0(1), P_0(2), \dots) \begin{pmatrix} P_{11} & P_{12} & \dots \\ P_{21} & P_{22} & \dots \\ \vdots & \vdots & \ddots \end{pmatrix} = (P_1(1), P_1(2), P_1(3), \dots)$$

III co drugą polozycí

$$(P_{ij}^{(k)}) \longleftrightarrow P_{ij}$$

$P_n(x) \Leftrightarrow$  množstvo čísel, či je číslo  
 $n$  z nich klesá pri  
 hodnotách  $x$

$$\lim_{k \rightarrow \infty} P_{ij}^{(k)} = ?$$

$$\lim_{n \rightarrow \infty} P_n(x) = ?$$

$X \sim \dots$

$$P_{ij}^{(h-2)}(t_1, t_3) = \sum_k P_{ik}(t_1, t_2) P_{kj}(t_2, t_3)$$

$t_1 < t_2 < t_3$

also:

$$\begin{aligned} P_{ij}(t_1, t_3) &= P(X(t_3) = j \mid X(t_1) = i) = \\ &= \sum_k P(X(t_3) = j \cap X(t_2) = k \mid X(t_1) = i) \stackrel{P(A|B) = \frac{P(A \cap B)}{P(B)}}{=} \\ &= \sum_k \frac{P(X(t_3) = j \cap X(t_2) = k \cap X(t_1) = i)}{P(X(t_1) = i)} = \end{aligned}$$

$$= \sum_k \frac{P(X(t_3)=j \mid X(t_2)=k \cap X(t_1)=i) \cdot P(X(t_2)=k \mid X(t_1)=i))}{P(X(t_1)=i)} =$$

$$= \sum_k \underbrace{P(X(t_3)=j \mid X(t_2)=k \cap X(t_1)=i) \cdot P(X(t_2)=k \mid X(t_1)=i))}_{=}$$

$$= \sum_k P(X(t_3)=j \mid X(t_2)=k) \cdot P(X(t_2)=k \mid X(t_1)=i) =$$

$$= \sum_k P_{kj}(t_2, t_3) \cdot P_{ik}(t_1, t_2) =$$

$$= \sum_k P_{ik}(t_1, t_2) P_{kj}(t_2, t_3)$$